Motor de búsqueda léxico y BM25

Análisis de aciertos y del límite de la búsqueda exacta

David Segundo García

Actividad 2A · 30 de agosto de 2026

1. Sistema evaluado

Se implementó desde cero, en un *notebook* de Jupyter, un buscador léxico completo sobre un corpus propio de **120 documentos en español** repartidos en **12 temáticas** (inteligencia artificial, astronomía, salud, gastronomía, deportes, economía, medio ambiente, historia, arte, transporte, ciberseguridad y viajes). El sistema tiene tres piezas:

1. **Preprocesamiento.** Minúsculas → tokenización con expresión regular que descarta puntuación → filtro de tokens de un carácter → eliminación de 368 *stopwords* → *stemming* Snowball para español → supresión de tildes en la raíz. La **misma** función se aplica al corpus y a la consulta, condición sin la cual los términos no serían comparables.
2. **Índice invertido** con diccionarios nativos: `término → {documento: tf}`, más las longitudes $|D|$, la frecuencia documental *df* y la longitud promedio *avgdl*.
3. **Ranking BM25** con $k_1 = 1.5$, $b = 0.75$ e IDF de Robertson en su variante de Lucene, verificado contra el cálculo manual de la fórmula.

$$\text{score}(D,Q) = \sum_{i=1}^{n} \text{IDF}(q_i) \cdot \frac{f(q_i,D)\,(k_1+1)}{f(q_i,D) + k_1\left(1 - b + b\dfrac{|D|}{\text{avgdl}}\right)}, \qquad \text{IDF}(q_i) = \ln\left(\frac{N - n(q_i) + 0.5}{n(q_i) + 0.5} + 1\right)$$

Corpus		**Índice**	
Documentos	120	Términos únicos (vocabulario)	1 940
Temáticas	12	Entradas de *postings*	3 608
Palabras crudas	6 369	Longitud promedio *avgdl*	32.50
Tokens indexables	3 900	Rango de $\|D\|$	24 – 45
Reducción tras limpiar	38.8 %	Términos con $df = 1$	1 211 (62.4 %)

2. Metodología de evaluación

Se definieron 14 consultas con su **categoría esperada** como criterio de relevancia. Sobre ellas se calcularon tres métricas: **P@5** (estricta, con denominador 5), **P@k efectiva** (sobre los documentos realmente recuperados) y **MRR**.

Métrica	**Valor**	**Interpretación**
MRR	**1.000**	El documento correcto quedó primero en las 14 consultas
P@k efectiva (promedio)	0.682	Dos de cada tres resultados devueltos son de la categoría esperada
P@5 estricta (promedio)	0.500	Penaliza los huecos: varias consultas recuperan menos de 5 documentos

La brecha entre ambas precisiones no indica error de ranking sino **cobertura**: con solo diez documentos por temática, consultas muy específicas como *«nixtamalización del maíz para tortillas»* recuperan un único documento —el correcto— y la P@5 estricta las castiga con 0.2. La categoría es además un criterio duro: en *«energía solar y eólica renovable»* los documentos de transporte sobre baterías y motores eléctricos cuentan como fallo aunque sean pertinentes. Las cifras son, por tanto, una cota inferior de la calidad real.

3. Casos en los que el buscador fue preciso

Caso 1: términos raros — «nixtamalización del maíz para tortillas»

Las tres raíces de la consulta (`nixtamaliz`, `maiz`, `tortill`) tienen $df = 1$, es decir, aparecen en un único documento del corpus. Su IDF es el máximo posible (4.39) y ningún otro documento puede competir:

Término	tf	df	IDF	Aporte BM25
nixtamaliz	2	1	4.3903	6.1802
maiz	2	1	4.3903	6.1802
tortill	1	1	4.3903	4.3010
			Total	**16.6614**

El desglose exhibe además la **saturación** de k_1: duplicar la frecuencia (de $tf = 1$ a $tf = 2$) sube el aporte de 4.30 a 6.18, no a 8.60. El décimo hallazgo de una palabra no vale diez veces el primero, que es exactamente lo que distingue a BM25 de un TF-IDF ingenuo.

Caso 2: acumulación de evidencia — «ransomware respaldo y cifrado»

Ningún término es tan raro como en el caso anterior, pero los tres coinciden en el mismo documento (*Ransomware y recuperación*, score 14.04) mientras que el resto de candidatos acierta solo uno o dos. La suma de aportes separa con claridad al primero: BM25 premia la **cobertura de la consulta**, no la repetición de un único término.

Caso 3: normalización por longitud — «energía»

Con un solo término en la consulta, dos documentos tienen $tf = 2$: *Energía solar fotovoltaica* ($|D| = 30$) y *Materia oscura y energía oscura* ($|D| = 37$). Con $b = 0.75$ gana el documento más corto (4.283 frente a 3.999), porque concentra la misma evidencia en menos texto. Al fijar $b = 0$ ambos empatan en 4.177: la normalización por *avgdl* es lo único que los separa.

4. Caso de fallo por búsqueda exacta: los sinónimos

El corpus se redactó deliberadamente usando *automóvil*, *médico* y *computadora*, y evitando por completo *coche*, *doctor* y *ordenador*. BM25 es un modelo **léxico**: puntúa coincidencia de cadenas, no de significados. Un término ausente del vocabulario tiene $df = 0$, su IDF se define como 0 y su aportación al ranking es exactamente cero. El resultado son **tres modos de fallo distintos**, de gravedad creciente:

Consulta	Raíces	df	Primer resultado	Score
coche eléctrico	coch, electr	0, 5	Automóviles eléctricos y autonomía	5.017
automóvil eléctrico	*automovil, electr*	*2, 5*	*Automóviles eléctricos y autonomía*	*10.373*
doctor	doctor	0	— sin resultados —	0.000
médico	*medic*	*1*	*Prevención de la diabetes tipo 2*	*4.187*
ordenador	orden	2	Chocolate desde el cacao	4.077
computadora	*comput*	*4*	*Visión por computadora*	*4.460*

1. Degradación silenciosa. *«coche eléctrico»* sí devuelve resultados, pero por el motivo equivocado: `coch` aporta 0.0 y todo el orden lo decide `electr`. El score del documento correcto cae de 10.373 a 5.017, y compite en igualdad con documentos sobre energía solar o baterías que también contienen *eléctrico*. Basta un corpus algo mayor para que el documento buscado deje de aparecer en el Top-5.

2. Cero resultados. La consulta *«doctor»* devuelve una lista vacía: ningún término aporta puntuación y el conjunto de candidatos queda vacío. El corpus habla de médicos, de telemedicina y de especialistas en varios documentos, pero el buscador no tiene forma de saberlo.

3. Falso positivo por colisión de raíces (el más grave). *«ordenador»* es reducido por el *stemmer* a `orden`, raíz que el corpus usa en «el templado *ordena* los cristales de manteca de cacao». El primer resultado es un documento sobre chocolate, presentado con la misma confianza que cualquier acierto. Lo mismo ocurre con *«cita con el doctor»*: la raíz `cit` aparece en «las cuatro grandes *citas* del calendario» y el buscador responde con un documento de tenis (score 3.801). El *stemming*, que en general mejora el recall, aquí fabrica una coincidencia que no existe. **Un resultado equivocado es peor que ningún resultado**, porque no hay señal alguna de que la consulta se entendió mal.

5. Mitigaciones evaluadas

Expansión de consulta con diccionario de sinónimos (implementada). Antes de puntuar se añaden a la consulta las variantes conocidas de cada término. No requiere reconstruir el índice y su costo es prácticamente

nulo. Recupera los tres casos: *coche eléctrico* pasa de 5.017 a **10.373**, *cita con el doctor* deja de responder tenis para devolver un documento médico (4.187) y *ordenador* recupera *Visión por computadora* (4.460). Su límite es estructural: solo cubre lo que alguien anticipó; *«vehículo de cero emisiones»* seguiría fallando.

Recuperación densa e híbrida (discutida). Representar consulta y documentos como vectores densos sitúa *coche* y *automóvil* próximos en el espacio semántico aunque no compartan una sola letra.

Enfoque	**Sinónimos**	**Términos raros**	**Costo**	**Explicabilidad**
BM25 (léxico)	No	Excelente	Muy bajo, CPU	Total
Denso (*embeddings*)	Sí	Débil	Alto	Baja
Híbrido (BM25 + denso)	Sí	Buena	Medio-alto	Media

6. Conclusiones

1. El preprocesamiento fija el techo del sistema: redujo 6 369 palabras a 3 900 términos indexables y es lo que permite que *baterías* recupere documentos que escriben *batería*. Cualquier asimetría entre el camino del corpus y el de la consulta rompe la recuperación sin producir ningún error visible.
2. BM25 acierta de forma consistente cuando consulta y documento comparten vocabulario: MRR de 1.000 en las 14 consultas evaluadas. Los aciertos más nítidos son los de términos con *df* bajo, donde el IDF domina la suma de aportes.
3. Los tres componentes de la fórmula son verificables por separado, pero su efecto agregado en un corpus de 120 documentos de longitud homogénea es pequeño: conviene no sobreinterpretar una tabla de sensibilidad de k_1 y b calculada a esta escala.
4. El fallo por sinónimos no es un defecto de implementación sino el límite del modelo, y su forma más peligrosa no es la lista vacía sino el falso positivo por colisión de raíces.
5. La elección de mitigación es una decisión de costo: un diccionario de sinónimos resuelve lo previsible con costo nulo; la recuperación densa resuelve el caso general a cambio de un modelo, un índice vectorial y una pérdida de explicabilidad. La práctica actual —y la razón por la que BM25 sigue vigente treinta años después— es combinar ambas señales en un recuperador híbrido.